

# Especificación Formal del Detector de Spam

Análisis Léxico y Sintáctico con Gramática Libre de Contexto

Juan Esteban López Aránzazu - 2313026

Víctor Manuel Álzate Morales - 2313022

5 de junio de 2026

## 1. Gramática Formal

### 1.1 Definición Formal

La gramática del detector de spam se define como una cuádrupla:

$$G = (V, T, P, S)$$

donde:

- $V$ : conjunto de símbolos no-terminales
- $T$ : conjunto de símbolos terminales (tokens)
- $P$ : conjunto de producciones (reglas de derivación)
- $S$ : símbolo inicial

### 1.2 Componentes

**Símbolo Inicial:**

$$S \in V$$

**Símbolos No-Terminales (V):**

El conjunto  $V$  agrupa los no-terminales en tres niveles jerárquicos:

|                                      |                                                                     |
|--------------------------------------|---------------------------------------------------------------------|
| <b>Nivel 1: Clasificación</b>        | S, SPAM, SOSPECHOSO, NORMAL                                         |
| <b>Nivel 2: Sintagmas Abstractos</b> | SN_S, SN_O                                                          |
| <b>Nivel 3: Variantes con Género</b> | SN_S_M, SN_S_F, SN_S_I, SN_S_PL,<br>SN_O_M, SN_O_F, SN_O_I, SN_O_PL |

**Símbolos Terminales (T):**

Los terminales son tokens clasificados en categorías semánticas:

$$\begin{aligned} T = & \{\text{IMP}, \text{PROM}, \text{BEN}, \text{ALERT}, \text{VERB}\} \\ & \cup \{\text{DET\_M}, \text{DET\_F}, \text{DET\_I}, \text{DET\_PL}\} \\ & \cup \{\text{SUJ\_M}, \text{SUJ\_F}\} \\ & \cup \{\text{OBJ\_M}, \text{OBJ\_F}, \text{OBJ\_PL}\} \end{aligned}$$

- **Tokens de Spam:** IMP (imperativo), PROM (promoción), BEN (beneficio), ALERT (alerta)
- **Determinantes:** DET\_M (masc.), DET\_F (fem.), DET\_I (invariable), DET\_PL (plural)
- **Sustantivos:** SUJ\_M, SUJ\_F (sujetos), OBJ\_M, OBJ\_F, OBJ\_PL (objetos)
- **Verbos:** VERB

### 1.3 Producciones (P)

Las producciones se organizan por no-terminal. Usamos la notación:

$$A \rightarrow \alpha_1 \mid \alpha_2 \mid \cdots \mid \alpha_n$$

**Nivel de Clasificación:**

$$S \rightarrow \text{SPAM} \mid \text{SOSPECHOSO} \mid \text{NORMAL}$$

**Nivel de Categoría (SPAM):**

$$\begin{aligned} \text{SPAM} \rightarrow & \text{IMP IMP PROM BEN} \mid \text{IMP PROM BEN ALERT} \mid \text{IMP ALERT PROM BEN} \\ & \mid \text{ALERT IMP PROM BEN} \mid \text{IMP PROM ALERT} \mid \text{IMP BEN PROM} \\ & \mid \text{IMP PROM PROM} \mid \text{IMP PROM BEN} \end{aligned}$$

**Nivel de Categoría (SOSPECHOSO):**

$$\begin{aligned} \text{SOSPECHOSO} \rightarrow & \text{ALERT IMP PROM} \mid \text{SN\_S IMP PROM} \mid \text{VERB PROM BEN} \mid \text{IMP PROM SN\_S} \\ & \mid \text{SN\_S IMP DET\_M PROM} \mid \text{SN\_S IMP DET\_F PROM} \mid \text{SN\_S IMP DET\_I PROM} \\ & \mid \text{IMP PROM} \mid \text{PROM BEN} \mid \text{IMP BEN} \\ & \mid \text{PROM ALERT} \mid \text{IMP ALERT} \mid \text{ALERT PROM} \end{aligned}$$

**Nivel de Categoría (NORMAL):**

$$\begin{aligned} \text{NORMAL} \rightarrow & \text{SN\_S SN\_S VERB SN\_O} \mid \text{SN\_S VERB SN\_S SN\_O} \mid \text{SN\_S VERB SN\_O SN\_O} \\ & \mid \text{VERB SN\_O SN\_O} \mid \text{SN\_S VERB SN\_O} \mid \text{SN\_S VERB} \mid \text{VERB SN\_O} \end{aligned}$$

**Sintagmas Nominales Abstractos:**

$$\begin{aligned} \text{SN\_S} & \rightarrow \text{SN\_S\_M} \mid \text{SN\_S\_F} \mid \text{SN\_S\_I} \mid \text{SN\_S\_PL} \\ \text{SN\_O} & \rightarrow \text{SN\_O\_M} \mid \text{SN\_O\_F} \mid \text{SN\_O\_I} \mid \text{SN\_O\_PL} \end{aligned}$$

**Sintagmas Nominales con Concordancia de Género:**

$$\begin{aligned} \text{SN\_S\_M} & \rightarrow \text{DET\_M SUJ\_M} \mid \text{SUJ\_M} \\ \text{SN\_S\_F} & \rightarrow \text{DET\_F SUJ\_F} \mid \text{SUJ\_F} \\ \text{SN\_S\_I} & \rightarrow \text{DET\_I SUJ\_M} \mid \text{DET\_I SUJ\_F} \\ \text{SN\_S\_PL} & \rightarrow \text{DET\_PL SUJ\_M} \mid \text{DET\_PL SUJ\_F} \\ \\ \text{SN\_O\_M} & \rightarrow \text{DET\_M OBJ\_M} \mid \text{OBJ\_M} \\ \text{SN\_O\_F} & \rightarrow \text{DET\_F OBJ\_F} \mid \text{OBJ\_F} \\ \text{SN\_O\_I} & \rightarrow \text{DET\_I OBJ\_M} \mid \text{DET\_I OBJ\_F} \\ \text{SN\_O\_PL} & \rightarrow \text{DET\_PL OBJ\_PL} \mid \text{OBJ\_PL} \end{aligned}$$

## 2. Análisis Léxico

### 2.1. Autómata Finito Determinista (AFD)

El análisis léxico constituye la primera etapa del sistema y tiene como objetivo transformar el texto de entrada en una secuencia de categorías léxicas utilizadas posteriormente por la gramática libre de contexto.

Formalmente, el analizador puede representarse mediante el autómata:

$$A = (Q, \Sigma, \delta, q_0, F)$$

donde:

- $Q$ : conjunto finito de estados.
- $\Sigma$ : alfabeto de entrada (caracteres del mensaje).
- $\delta : Q \times \Sigma \rightarrow Q$ : función de transición.
- $q_0$ : estado inicial.
- $F$ : conjunto de estados de aceptación.

El autómata procesa cada palabra del mensaje y la clasifica según una categoría léxica definida en el diccionario del sistema.

### 2.2. Categorías léxicas

Las principales categorías utilizadas por el sistema son las siguientes:


| Categoría | Ejemplos                       | Descripción                                               |
|-----------|--------------------------------|-----------------------------------------------------------|
| IMP       | gana, obtén, consigue, reclama | Verbos imperativos frecuentes en mensajes promocionales.  |
| PROM      | premio, dinero, oferta, bono   | Palabras asociadas a recompensas o beneficios económicos. |
| BEN       | gratis, exclusivo, garantizado | Términos que enfatizan ventajas o beneficios.             |
| ALERT     | urgente, ahora, hoy, limitado  | Expresiones de presión temporal o urgencia.               |
| VERB      | revisa, consulta, verifica     | Verbos utilizados en mensajes informativos normales.      |
| DET_M     | el, un, este                   | Determinantes masculinos.                                 |
| DET_F     | la, una, esta                  | Determinantes femeninos.                                  |
| DET_I     | mi, tu, su                     | Determinantes invariantes respecto al género.             |
| SUJ_M     | equipo, sistema                | Sustantivos masculinos empleados como sujeto.             |
| SUJ_F     | empresa, plataforma            | Sustantivos femeninos empleados como sujeto.              |
| OBJ_M     | informe, documento, reporte    | Objetos masculinos.                                       |
| OBJ_F     | factura, propuesta, solicitud  | Objetos femeninos.                                        |
| OBJ_PL    | documentos, facturas, datos    | Objetos en plural.                                        |

Cuadro 1: Categorías léxicas utilizadas por el sistema

### 3. Integración del Sistema

#### 3.1. Arquitectura General

El sistema está compuesto por cuatro módulos principales que trabajan de forma secuencial para analizar y clasificar mensajes en español.



#### 3.2. Pipeline de Procesamiento

El procesamiento de cada mensaje sigue las siguientes etapas:

1. **Análisis Léxico (lexico.py)**

- Tokeniza el texto de entrada.
- Normaliza palabras (minúsculas y eliminación de acentos).
- Asigna una categoría léxica a cada token.
- Produce una secuencia de categorías gramaticales.

```
tokens = tokenizar(texto)
categorias = categorizar(tokens)
```

## 2. Parser Sintáctico (parser.py)

- Implementa un parser descendente recursivo.
- Verifica si la secuencia pertenece al lenguaje generado por la CFG.
- Construye el árbol de derivación correspondiente.

```
arbol = parse("S", categorias)
```

## 3. Clasificación (clasificador.py)

- Analiza la estructura sintáctica reconocida.
- Determina si el mensaje corresponde a una estructura SPAM, SOSPECHOSO o NORMAL.

```
categoria = clasificar(arbol)
```

## 4. Evaluación Probabilística (pcfg.py)

- Calcula la probabilidad del árbol sintáctico.
- Permite comparar diferentes interpretaciones.
- Proporciona una medida de confianza para la clasificación.

```
probabilidad = prob_arbol(arbol)
```

### 3.3. Concordancia Gramatical

La gramática incorpora reglas específicas para representar la concordancia de género en español mediante sintagmas nominales especializados.

Por ejemplo:

$$SN_S \Rightarrow SN_{S_F} \Rightarrow DET_F \text{ } SUJ_F \Rightarrow \text{“la empresa”}$$

La derivación anterior es válida porque el determinante femenino `DET_F` concuerda con el sustantivo femenino `SUJ_F`.


Por el contrario, secuencias como:

*el empresa*

no pueden generarse mediante la gramática y son rechazadas por el parser.

### 3.4. Integración entre Componentes

La interacción entre módulos puede resumirse mediante el siguiente flujo:



### 3.5. Herramientas Utilizadas

| Herramienta | Función                       |
|-------------|-------------------------------|
| Python 3    | Implementación del sistema    |
| re          | Tokenización y normalización  |
| typing      | Tipado estático               |
| dataclasses | Representación de estructuras |
| CFG         | Análisis sintáctico           |
| PCFG        | Clasificación probabilística  |

Cuadro 2: Tecnologías utilizadas

## 4. Conclusión

En este proyecto se implementó un detector de spam para mensajes en español utilizando herramientas formales de Procesamiento de Lenguaje Natural. El sistema integra un análisis léxico para la identificación de categorías gramaticales, una Gramática Libre de Contexto (CFG) para el reconocimiento de estructuras sintácticas y una Gramática Libre de Contexto Probabilística (PCFG) para apoyar la clasificación de los mensajes.

La solución desarrollada permite clasificar mensajes en las categorías *SPAM*, *SOSPECHOSO* y *NORMAL* a partir de su estructura lingüística, demostrando la aplicación práctica de los conceptos estudiados durante el curso, tales como análisis léxico, gramáticas formales, parsers y modelos probabilísticos.

Además, la arquitectura propuesta es fácilmente extensible, ya que permite incorporar nuevas categorías léxicas, reglas gramaticales y probabilidades sin modificar la estructura general del sistema.